高书恒 Tele: 13635806059 WX: G166232 HomePage: aaadrown.github.io

- 华中科技大学 计算机卓越计划实验班 2021.9-2025.6 GPA 4.6 Rank 2/30
- 中国科学技术大学 计算机科学与技术 2025.9-2028.6
- 2024 华为ICT云计算赛道全国一等奖 2022全国数学建模竞赛湖北省一等奖
- 熟悉vLLM/SGLang等推理框架优化，PD分离调度，KVCache缓存管理
- 熟悉CUDA Runtime/Driver软件栈，熟悉Serverless/K8S推理集群调度优化
- 熟悉常见算法与数据结构，计算机网络，体系结构，Linux 操作系统等
- 熟悉Raft/Zab 等分布式存储场景的一致性算法原理



实习经历

中国电信研究院 AI Infra Research | 2026.2 – 2026.6

- **VLM近似缓存**：基于CacheBlend等PIC缓存复用，设计了重算+复用的近似缓存方案。在Warmup层对语义注意力重要的Patch直接重算，对于低熵的图片背景等Patch近似复用。在VisionArena/MathVision等多模态数据集上实现了**基本无损**的图片近似复用。在**4卡H100**在线推理系统的整体缓存命中率达到**52.6%，**系统**整体吞吐提高17.4%。(命中缓存的TTFT提高38.2%，TPOT提高47.8%)**
- **DiT推理加速：**在Wan2.1长视频生成场景中通过Embedding/Rerank模型检索潜在的近似复用请求，对高噪步的Latent Cache近似复用，显著提高高清(4K)视频的生成效率。

百度深圳研发中心 国际化产品线| 2024.10 – 2024.12

- 基于Langchain/LlamaIndex 等 RAG 组件，实现Chatgpt/PixalAI接口的文本，图像等流式AI Bot 产品。
- 对集群服务搭建 promtail+loki+grafana 的轻量日志收集与分析系统，实现问题日志的实时定位发现与组合查询

腾讯科技(深圳)有限公司 PCG 社交安全中心 | 2024.4 – 2024.9

- 对 PCG 旗下所有重点业务的多模态内容审核的打击策略进行准确率抽样，实现了打击策略粒度的准确率统计
- 通过接口编排实现业务策略数据分析平台的开发，集成统计分析模板，业务，策略，基础服务等各个维度的业务数据
- 基于 lua 配置化脚本的编排平台实现 QQ 小世界内容信息的审核/打击策略，了解 lua 状态机，热更新原理

科研经历

面向Serverless推理的通用GPU显存重删框架| 2025.6 – 2025.11

- 针对Serverless LLM私有部署场景存在的显存冗余问题，提出了GPU用户态驱动级的通用显存重删框架
- 实现CUDA VMM页粒度显存管理，利用卡间NVLink高带宽实现低开销的跨实例跨框架的通用显存共享模式
- 基于CPU/GPU协同页Hash管理，针对不同访存模式设计多种重删策略以及用户态与内核态交互的GPU写时复制
- 在**4卡A100**上较ServerlessLLM推理**显存降低59.8%**，**平均TTFT提高22.7%**，资源受限场景下**吞吐提高至2倍。**

面向资源受限场景的混合推理系统实现 | 2024.11 – 2025.4

- 基于 llama.cpp，实现了一套面向资源受限场景下的 Prefill 和 Decode 二阶段混合推理系统
- Prefill 阶段，设计了一套硬件感知的自适应 GPU 推理流水线，实现了以模型层为粒度的计算加载高效并行
- Decode 阶段，将FFN冷热神经元分别放置在内存与显存中，由 CPU 和 GPU 动态剪枝计算并合并
- 在不同输入长度下的端到端性能**较 PowerInfer 提升 2.3 倍，较 llama.cpp 提升 3.7 倍**

腾讯云硬盘写流量负载预测调度 | 2023.11-2024.4

- 面向腾讯虚拟云硬盘调度场景，针对高写带宽特性的SSD云硬盘，从周期性/突发性等分析写负载模式
- 通过业务标签，用户元数据等信息对云硬盘写流量分类预测，针对每一种写负载设计不同的调度策略
- 对 EMR/Spark 等突发性强，难以预测的离线批处理写负载设计一套创新的调度算法，实现集群间负载均

论文

- gKSM: GPU Memory Deduplication at Driver Layer for Serverless LLM Inference (ATC26, 一作, CCF-A)
- Visual Cache Reuse for Efficient Multimodal Inference（Eurosys27, 一作在投, CCF-A)
- VDMig: An Adaptive Virtual Disk Migration Scheme For Cloud Block Storage System (ICCD24, CCF-B)
- Token Write Amplification in LLM-Mediated State Stores (Hotstorage26, CCF-C, Best Paper Award)