高书恒 Tele: 13635806059 WX: G166232 HomePage: aaadrown.github.io

- 华中科技大学 计算机卓越计划实验班 2021.9-2025.6 GPA 4.6 Rank 2/30
- 中国科学技术大学 计算机科学与技术 2025.9-2028.6
- 2024 华为ICT云计算赛道全国一等奖 2022全国数学建模竞赛湖北省一等奖
- 熟悉vLLM/SGLang等推理框架优化，PD分离调度，KVCache缓存管理
- 熟悉CUDA Runtime/Driver软件栈，熟悉Serverless/K8S推理集群调度优化
- 熟悉常见算法与数据结构，计算机网络，体系结构，Linux 操作系统等
- 熟悉Raft/Zab 等分布式存储场景的一致性算法原理



实习经历

百度深圳研发中心 Agentic RL Infra| 2026.6 – 2026.10

- 为 Slime 适配 MagiAttention TreeMask，复用 Agentic RL 多样本间的共享前缀，减少长上下文场景下的冗余计算。基于 Token 级前缀树优化动态组批，结合 Sparse Table O(1) 查询与 Token 分块，将 Host 侧开销降低约 95%。在共享前缀占比约 80% 的测试中，实现 logprob kernel 加速 **4倍**，训练加速 **2.4倍**，端到端加速 **1.5倍。**
- 修复EPLB+CUDA Graph的乱码问题，分析EPLB对Moonlight 16B等不同模型的推理性能提升差异。

中国电信研究院 AI Infra Research | 2025.12 – 2026.6

- **VLM近似缓存**：基于CacheBlend等PIC缓存复用，设计了重算+复用的近似缓存方案。在Warmup层对语义注意力重要的Patch直接重算，对于低熵的图片背景等Patch近似复用。在多项多模态数据集上实现**基本无损**的输出精度。**4卡H100**在线推理的整体缓存命中率达到**52.6%，**系统**吞吐提高17.4%。(命中缓存的TTFT提高38.2%，TPOT提高47.8%)**
- **MLA Rollout 加速：**针对MLA架构TP无法切分Compressed Vector 导致上下文 KV cache 大量冗余问题，使用DP-Attention+MTP 设计长文本下高速 Rollout 方案，并且通过 SpecV2 来掩盖通信与 Kernel 启动开销，端到端提速 4.1x。

腾讯科技(深圳)有限公司 PCG 社交安全中心 | 2024.4 – 2024.9

- 对重点业务的多模态内容审核的打击策略进行准确率抽样，实现了打击策略粒度的准确率统计
- 通过接口编排实现业务策略数据分析平台的开发，集成统计分析模板，业务，策略，基础服务等各个维度的业务数据

科研经历

面向Serverless推理的通用显存重删框架 (gKSM@ATC'26)

- 针对Serverless LLM公有云场景存在的显存冗余问题，提出了驱动层的通用显存重删框架
- 实现CUDA VMM页粒度显存管理，利用卡间NVLink高带宽实现低开销的跨实例跨框架的通用显存共享
- 基于CPU/GPU协同页Hash管理，针对不同访存模式设计多种重删策略以及用户态与内核态交互的GPU写时复制
- 在**4卡A100**上较ServerlessLLM推理**显存降低59.8%**，**平均TTFT提高22.7%**，资源受限场景下**吞吐提高至2倍。**

腾讯云硬盘写流量负载预测调度 (VDMig@ICCD'24)

- 面向腾讯虚拟云硬盘调度场景，针对高写带宽特性的SSD云硬盘，从周期性/突发性等分析写负载模式
- 通过业务标签，用户元数据等信息对云硬盘写流量分类预测，针对每一种写负载设计不同的调度策略
- 对 EMR/Spark 等突发性强，难以预测的离线批处理写负载设计一套创新的调度算法，实现集群间负载均

面向资源受限场景的混合推理系统

- Prefill 阶段，设计了一套硬件感知的自适应 GPU 推理流水线，实现了以模型层为粒度的计算加载高效并行
- Decode 阶段，将FFN冷热神经元分别放置在内存与显存中，由 CPU 和 GPU 动态剪枝计算并合并
- 在不同输入长度下的端到端性能**较 PowerInfer 提升 2.3 倍，较 llama.cpp 提升 3.7 倍**

论文

- gKSM: GPU Memory Deduplication at Driver Layer for Serverless LLM Inference (ATC26, 一作, CCF-A)
- Visual Cache Reuse for Efficient Multimodal Inference（Eurosys27, 一作在投, CCF-A)
- VDMig: An Adaptive Virtual Disk Migration Scheme For Cloud Block Storage System (ICCD24, CCF-B)
- Token Write Amplification in LLM-Mediated State Stores (Hotstorage26, CCF-C, Best Paper Award)